

인공지능 학습용 서버
(AI training server)

사전기획보고서

2026. 04. 20

한 국 재 료 연 구 원

목 차

1. 연구시설 · 장비의 개요	
가. 연구시설 · 장비명	
나. 연구시설 · 장비 분류	
다. 연구시설 · 장비 용도	
라. 연구시설 · 장비 사양 및 모델	
2. 연구시설 · 장비의 필요성	
가. 연구목적과의 부합성	
나. 연구시설 · 장비의 국가적 필요성	
다. 기관 연구장비 구축 로드맵과의 연계성	
3. 연구시설 · 장비의 구축현황	
가. 연구시설 · 장비 구축 현황 조사 결과	
나. 중복성 자체 점검 결과	
4. 연구시설 · 장비의 차별성	
가. 연구시설 · 장비의 혁신성 및 수용력	
나. 기존 연구시설 · 장비와의 차별성	
5. 연구시설 · 장비의 수요현황 조사	
가. 수요조사 목적	
나. 수요조사 내용	
다. 수요조사 결과	
6. 연구시설 · 장비의 도입의 적정성	
7. 연구시설 · 장비의 구축 계획	
가. 단계별 구축 전략	
나. 연구시설 · 장비 구축 환경	

8. 연구시설·장비의 운영 계획

- 가. 연구시설 · 장비 운영 재원
- 나. 연구시설 · 장비 운영 전문성 확보 계획
- 다. 연구시설 · 장비 운영 인력 현황

9. 연구시설·장비의 활용 계획

- 가. 연구시설 · 장비의 활용계획
- 나. 연구시설 · 장비의 공동활용계획
- 다. 국제 협력 연구과제 활용계획
- 라. 연구과제(사업) 종료 후 활용계획

10. 연구시설·장비의 구축에 따른 기대효과

- 가. 과학기술적 효과
- 나. 경제적 효과
- 다. 사회적 효과
- 라. 지역적 효과

11. 사전기획보고서 작성 절차 및 참여인력

12. 기타

- (붙임) 1. #####
2. #####
3. #####

1. 연구시설·장비의 개요

가. 시설·장비명

한글 시설·장비명 (국문 명칭을 기재)	인공지능 학습용 서버
영문 시설·장비명 (영문 명칭을 기재) ※영문 약어를 기재할 경우, 풀네임도 함께 기재 요망	AI training server

나. 시설·장비분류

분류1 (기술 분야) (해당란에 '○'표시)	기초과학	생명	해양	우주·천문	에너지	환경	기계부품소재	정보전자통신
분류2 (시설장비표준분류) (해당란에 '○'표시)	광학·전자 영상장비	화학물·전자 분석 장비	기계가공· 시험장비	전기·전자 장비	데이터 처리장비	물리적 측정 장비	임상의료 장비	환경조성· 사육시설
분류3 (중점투자분야) (해당란에 '○'표시)	주력 기간산업 기술 고도화	신산업 창출 핵심기술개발 강화	글로벌 이슈 대응 연구개발 추진	국기주도기술 핵심역량 확보	기초과학·융합기술 연구개발 활성화			

다. 시설·장비용도

용도 분류 (해당란에 '○'표시)	시험	분석	교육	제측	생산	기타(직접 기재)
용도 설명 (구체적인 용도 기술)						○ (인공지능 학습)
	○ 소재 특화 파운데이션 모델 학습 및 최적화 - 수백 중 이상의 합금계를 동시에 커버하기 위해 수십억 파라미터 규모로 설계된 멀티모달 파운데이션 모델을 사전학습하여, 열역학 데이터, 실험 물성 DB, EBSD/SEM 미세조직 이미지, XRD 데이터 등 이중 모달리티를 하나의 아키텍처 안에서 동시에 처리하면서 조성→공정→조직→물성의 인과 관계를 범용적으로 표현하는 소재 언어 모델을 구축 - 멀티모달 데이터를 하나의 통합 표현 공간으로 정렬하기 위해, 각 모달리티별 인코더와 cross-modal alignment 네트워크를 포함하는 대규모 모델을 대규모 고차원 데이터 세트에 대해 학습 - 사전학습 이후 특정 소재 시스템에 대한 파인튜닝과 함께, 수십억 파라미터 모델의 아키텍처·학습률·정규화 전략 등 대규모 하이퍼파라미터 탐색을 분산 학습 환경에서 병렬로 수행 ○ 대규모 고차원 데이터 처리 및 고해상도 생성 모델의 대규모 학습					

- 실험 데이터가 최소한 조성·공정 영역(고온 장시간 크리프, 극한 조성 등)에 대해 결정립 크기 분포, 상 분율, 석출물 형상·분포 등 미세조직의 복잡한 형태학적 특징을 고해상도 3D로 재현할 수 있는 수십억 파라미터 규모의 생성 모델을 학습하되, 고해상도 3D 텐서를 배치 단위로 GPU 메모리에 상주시키면서 물리 기반 시뮬레이션(CALPHAD, FEA 등)과의 정합성 검증 파이프라인을 학습과 동시에 실행
 - 생성된 합성 미세조직 이미지와 물성 분포의 물리적 타당성을 보장하기 위해, 열역학·역학적 제약 조건을 모델 학습 목적함수에 직접 통합하고, 대규모 합성 데이터를 다운스트림 물성 예측 모델의 학습 데이터로 활용하는 전체 데이터 생성-검증-활용 파이프라인을 운영
- AI 시뮬레이터 학습
- 미세조직에 따른 기계적 거동 및 공정 조건에 따른 미세조직 변화(상변태, 결정립 성장, 석출 거동 등)를 기존의 물리 기반 수치 해석 대신 예측할 수 있는 AI 시뮬레이터를 학습하되, 고해상도 3D 공간장(응력/변형률 텐서장, 상 분율장 등)의 시간 발전을 다수의 시간 스텝에 걸쳐 예측해야 하므로 입출력 텐서의 차원이 매우 크고 모델 용량이 수십억 파라미터 규모로 커야 하며, 학습 데이터 역시 물리 기반 시뮬레이션으로 생성한 데이터 활용
 - 다양한 초기 미세조직 조건과 공정·부하 경로 조합에 대해 범용적으로 작동하도록, 조건부 입력의 조합 공간이 매우 넓은 상태에서 학습 실험(아키텍처 탐색, 시간 스텝 전략, 물리 제약 조건 가중치 등)을 분산 환경에서 동시 병렬 수행
- 다중 모델 기반 통합 소재 설계 파이프라인 운영
- 학습 완료된 파운데이션 모델, 생성 모델, AI 시뮬레이터 등을 단일 노드의 GPU 메모리에 동시에 상주시키고, 후보 조성·공정 제안 → 미세조직 생성 → 다중 부하 경로 물성 예측 → 불확실성 평가 → 설계 기준 판정의 전체 루프를 모델 스와핑 없이 반복하는 역설계 파이프라인 구축 및 운영
- 금속소재 특화 LLM 에이전트의 학습 및 추론 운영
- 금속소재 논문, 특허, 실험 프로토콜, 기술 보고서 등 도메인 텍스트 코퍼스로 대규모 언어 모델을 파인튜닝하여, 연구 목표를 자연어로 입력하면 이를 하위 작업(조성 탐색, 미세조직 생성, 물성 예측, 실험 조건 제안 등)으로 분해하고 상기 파운데이션 모델, 생성 모델, 그리고 AI 시뮬레이터를 자율적으로 호출을 반복하는 에이전트 구축
 - 에이전트 LLM 자체가 수십억~수백억 파라미터 규모이면서 동시에 호출 대상인 도메인 모델들도 GPU에 상주해야 하므로, 에이전트 추론과 도구 모델 추론이 단일 노드 내에서 동시에 이루어져야 하며, 에이전트가 수백~수천 회의 추론-판단-재호출 루프를 반복하는 과정에서 모델 간 데이터 전달 지연이 최소화되어야 실용적인 응답 시간 내에 자율 설계 사이클 완료 가능

라. 시설·장비사양 및 모델명

핵심 요구 성능 (핵심적인 요구 성능 기술, 예 : 해상도 000이상 등)	○ GPU 메모리 - 수십억 파라미터 규모의 다중 대규모 모델(파운데이션 모델, 생성 모델, AI 시뮬레이터 등)을 단일 노드에 동시 상주시키기 위해 시스템 총 GPU 메모리 2,000GB 이상 ○ 연산 성능 - 대규모 모델의 추론 서빙 및 합성 데이터 생성 파이프라인에서 FP4 양자화를 활용한 고처리량 연산이 가능해야 하며, FP4 Tensor Core 기준 100 PFLOPS(dense) 이상의 연산 성능 ○ 노드 내 GPU 간 통신 대역폭 - 8-GPU 전체를 활용한 텐서 병렬화(TP) 시 GPU 간 통신이 연산과 오버랩되어야 하므로, NVLink aggregate 대역폭 14TB/s 이상 ○ 노드 간 네트워크 대역폭 - 멀티노드 분산 학습 확장 시 gradient 동기화 병목을 최소화하기 위해 노드당 800Gb/s 이상의 InfiniBand/Ethernet 네트워킹 ○ 소프트웨어 스택 - 멀티유저 GPU 오케스트레이션, 학습 중 자동 장애 복구, 인메모리 체크포인팅, NVLink 토폴로지 인식 스케줄링을 포함하는 턴키 AI 팩토리 운영 소프트웨어가 하드웨어와 통합 제공되어야 하며, Slurm 및 Kubernetes 환경 모두 지원
상세사양 (주장비, 부대장비 등 신청 장비에 대한 상세사양을 기술)	○ NVIDIA DGX B300 - GPU: 8× NVIDIA Blackwell Ultra 270GB - GPU 메모리: 2,160GB (8× 270GB) - CPU: Dual Intel Xeon 6776P Processors (128 Cores, 2.3 GHz, MAX 3.9 GHz) - 시스템 메모리: 2TB - NVSwitch: 2× NVIDIA NVSwitches (Total 14.4TB/s Bi-directional Bandwidth) - NVLink: 18× NVLinks Per GPU (1,800GB/s Per GPU to GPU Bi-directional Bandwidth) - 네트워킹(클러스터): 8× OSFP port serving 8× ConnectX-8 VPI (Up to 800Gb/s InfiniBand/Ethernet) - 네트워킹(스토리지): 2× Dual-port QSFP112 BlueField-3 DPU (Up to 400Gb/s InfiniBand/Ethernet) - 네트워킹(관리): 1× 1G RJ45 (BMC) / 1× 1G RJ45 (On-board)

	- 스토리지(OS): 2× 1.9TB M.2 NVMe SSDs - 스토리지(Cache): 8× 3.84TB E1.S NVMe SSDs - 운용 온도: 10°C ~ 35°C - Multi-Instance GPU: Various instance sizes with MIGs ○ NVIDIA DGX B300 Software Package - DGX Software Stack: Ubuntu Linux Host OS / Driver / NV Docker / Accelerated Solution - NVIDIA AI Enterprise Subscription per GPU, 3 Years (8식) - Mandatory Installation DGX B300, Partner Installed (1식) - NVIDIA GPU 사용 프로세스 병목 탐색 및 가이드 필수 제공 - CUDA Parallel Programming 교육 지원 - 엔비디아 코리아 정품 ○ GPU Rack System - 설치 환경에 맞는 랙 시스템 ○ 설치 및 교육 - 전체 장비 설치 완료 후 무료 활용 교육(Hw & SW) 교육 - 무상보증기간 최소 3년		
제작사 및 모델명 (입찰예정이면 표에 칸을 추가하여 제작사 및 모델명을 2개 이상 작성)	제작국가명	제작사명	모델명
	미국	NVIDIA	DGX-B300

2. 연구시설·장비의 필요성

가. 연구시설·장비의 연구목적과의 부합성

1) 사업 개요 및 연구 내용

- 전략연구사업 “금속소재 조성·공정 자동설계 초거대 AI 서비스 개발”을 통해 금속 소재 특화 파운데이션 모델을 개발하고, 이를 기업이 소재 및 공정 설계에 활용할 수 있도록 최종 서비스화하는 것이 핵심 목표
- 주요국은 거대 소재 AI를 기반으로 신소재 연구개발 패러다임 전환 및 산업 경쟁력 강화에 주력
 - 해외 주요국의 소재 AI 프로젝트들은 거대 모델 기반의 소재 AI 기술을 개발하여 소재 설계 공간을 효율적으로 탐색하고 유망 후보 소재를 신속하게 식별하는 성과
 - 하지만, 대부분 화학·유기 소재 중심으로 접근하고 있으며, 금속 소재에 특화된 초거대 AI 개발과 소재 개발 실증을 위한 조성·공정 레시피 제공은 제한적
- 소재 개발 분야에서 AI 활용은 주요국들을 중심으로 빠르게 확산되고 있으며 국내에서도 AI를 활용한 소재 개발 연구가 활발히 진행되고 있으나, 현재의 연구는 대부분 소형 AI 모델에 기반하고 있어 기술적·구조적 한계 존재
 - 기존 연구에 사용되는 AI 모델은 대부분 제한된 연산능력과 학습데이터를 바탕으로 하는 소형 AI 모델로, 기존 소재와 유사한 범위 내에서의 탐색에 국한되는 경향이 있음. 이로 인해 혁신적이고 파괴적인 신소재의 발굴 가능성은 제한적
 - AI의 도입은 확대되고 있으나, 전주기적 소재 개발을 아우를 수 있는 대형 AI 시스템이나 통합 플랫폼 구축은 아직 초기 단계로, 국제적 경쟁력을 확보하기에는 미흡
- 양질의 데이터를 생성 및 수집과 이를 기반으로 금속 소재 특화 파운데이션 모델을 개발하여 기업에 관련 서비스를 지원하는 기술 개발을 위해 다음과 같은 연구 내용을 수행:

연구개발 세부목표	주요 연구 내용
금속 소재 거대 AI 파운데이션모델 개발	○ 금속소재 멀티모달 파운데이션 모델 개발 ○ 조성·공정 최적화 기술 개발 ○ 전산재료과학 기반 AI 시뮬레이터 개발
금속 소재 멀티모달 빅데이터 구축	○ 금속 소재 자동화 실험실 기반 실험 빅데이터 구축 ○ 자동화 실험실 공정 제어 및 최적화 기술 개발
금속 소재 AI 서비스 플랫폼 및 연구데이터 전주기 시스템 구축	○ 금속소재 연구데이터 전주기 디지털화 시스템 개발 ○ 연구데이터 자동 수집 시스템 구축 및 지능형 운영 환경 구축 ○ 금속소재 설계 Agent 기반 AI 서비스 플랫폼 개발

2) 연구시설·장비의 구축 필요성

- 전략연구사업 “금속소재 조성·공정 자동설계 초거대 AI 서비스 개발” 과제 연구개발에 있어서 실험과 물리 기반 계산만으로 수급 불가한 막대한 양의 데이터를 수집하기 위해 금속 소재 합성 데이터(멀티모달 PSP(Process-Structure-Property) 모델, 조건부 생성형 모델, AI 시뮬레이터 등) 생성 모델 학습과 이를 활용한 금속 소재 특화 파운데이션 모델을 학습하기 위해 복수의 거대 AI 모델을 다수의 연구진이 병목 없이 고속으로 학습할 수 있는 대용량 메모리 기반의 다중 사용자 지원 고성능 GPU 서버 도입이 필수
- 사용자가 요구하는 목표 물성 범위와 허용 가능한 조성·공정 제약조건을 입력으로 받아 이를 만족시키는 합금 조성, 공정 경로, 예측 물성 및 대표 미세조직 이미지를 통합적으로 생성하고 추천하는 모델은 경량화 후에도 10B 이상 파라미터 규모의 모델 구축이 필요할 것으로 예상
 - 모델 구조 및 초거대 메모리: 조성·공정·미세조직·물성 데이터를 저차원 벡터 및 토큰 시퀀스로 변환하는 모달리티별 인코더와 10B 파라미터 이상의 백본(Backbone) 네트워크, 그리고 이를 다시 실제 데이터로 복원하는 디코더로 설계되며, 이러한 거대 가중치와 고차원 멀티모달 데이터 배치를 병목 없이 한 번에 처리하기 위해 노드당 총합 최소 2TB 이상의 최상위 고대역폭 메모리 공간 요구
 - 학습 데이터 및 초고속 대역폭: 실제 자동화 실험 데이터에 물리 시뮬레이션과 보조 모델(AI 시뮬레이터 등)이 만들어내는 대규모 합성 데이터를 결합하여 대량으로 증강된 초거대 고차원 이미지/비디오 학습 데이터 활용이 불가피하고 이러한 방대한 데이터를 10B 이상 거대 모델에 분산 학습시킬 때 필연적으로 발생하는 GPU 간 데이터 통신 지연을 막기 위해, 초당 10TB 이상의 양방향 통신 대역폭을 지원하는 초고속 상호 연결망 기반의 인프라 아키텍처 필수
 - GPU 연산량 및 다중 사용자 병렬 처리: 멀티모달 재료 상태를 수천 개의 토큰 시퀀스로 정의시, 스케일링 법칙($C \sim 6ND$)에 따라 10B 파라미터(N)와 수천억 토큰(D) 기준 1회 사전학습에만 최소 $10^{22} \sim 10^{23}$ FLOPs 수준의 연산량 발생할 수 있으며 하이퍼파라미터 튜닝을 위한 반복 재학습, 데이터 증강용 보조 생성 모델(수억 파라미터 규모)들의 동시 학습, 그리고 다수 연구진이 지연 없이 병렬적으로 과제를 수행하는 다중 사용자 환경까지 보장하려면 단일 노드 기준 수십 PFLOPS 이상의 강력한 부동소수점 연산 성능을 제공하는 최신 고성능 GPU 도입 필요
- 최종 서비스 단계에서 금속소재 도메인 특화 LLM 에이전트가 상기 파운데이션 모델, 생성 모델, AI 시뮬레이터를 자연어 기반으로 자율 호출, 해석, 반복 등을 하는 구조를 구현하기 위해, 에이전트 LLM 자체의 추론과 도구 모델들의 추론이 동일 노드 GPU 메모리에 동시 상주한 상태로 수행되어야 하며 이는 학습 단계와는 별도의 추가적인 GPU 메모리 점유 및 연산 부하를 발생시킴
 - 에이전트 LLM(수십억~수백억 파라미터)이 연구자 또는 기업 엔지니어의 자연어 요청("인장강

도 1.2GPa 이상, 연신을 15% 이상, Co 미사용 조건의 합금 조성 제안")을 해석하여 조성 탐색 → 미세조직 생성 → 물성 예측 → 결과 판단 → 재탐색의 설계 루프를 자율적으로 수행하는 과정에서, 매 호출마다 도구 모델 간 입출력 전달이 노드 내 NVLink를 통해 지연 없이 이루어져야 실용적 응답 시간 내에 설계 사이클 완료가 가능

- 에이전트 서버는 학습 완료 후 지속적으로 운영되는 상시 추론 워크로드이므로, 학습 작업과 추론 서버가 동일 인프라에서 시분할 또는 GPU 분할(MIG 등)로 병행될 수 있는 다중 워크로드 지원 환경이 요구되며, 이는 Mission Control(Run:ai) 기반 GPU 오케스트레이션을 통해 학습, 추론, 에이전트 서버 간 GPU 자원을 동적으로 재배분하는 운영 체계를 전제

3) 연구 목적과의 부합성

- 전략연구사업 “금속소재 조성·공정 자동설계 초거대 AI 서비스 개발”을 통해 금속 소재 특화 파운데이션 모델을 개발하고, 이를 기업이 소재 및 공정 설계에 활용할 수 있도록 최종 서비스화하는 것이 핵심 목표
- 이러한 최종 서비스화 목표를 성공적으로 달성하려면, 기업 현장에서 요구하는 수준의 신속한 결과 도출과 타겟 소재별 맞춤형 모델 업데이트 환경 구축 필요하며, 특히 10B 파라미터 규모 이상의 초거대 멀티모달 모델을 안정적으로 구동하고, 다수의 기업 사용자가 동시에 접속하여 최적화 과정을 지연 없이 처리하려면 대용량 메모리와 초고속 연산력을 갖춘 GPU 서버 도입이 본 과제의 최종 연구 목적과 완벽하게 일치
- 현재 글로벌 소재 AI 분야의 기술 패권 경쟁이 극도로 심화되는 상황 속에서, 막대한 합성 데이터의 생성부터 거대 파운데이션 모델의 사전학습, 검증, 그리고 기업 대상 서비스 배포에 이르는 전체 개발 주기를 획기적으로 단축하는 것이 매우 시급하고 만약 해당 스펙을 충족하는 고성능 컴퓨팅 인프라 확보가 지연될 경우, 막대한 연산량이 수반되는 초거대 모델의 학습 일정 지연 및 최종 서비스의 품질 저하가 불가피
- 따라서, 본 전략연구사업의 핵심인 초거대 AI 서비스의 적기 개발 및 실효성 있는 서비스 제공이라는 최종 목적을 차질 없이 달성하기 위해, 대규모 병렬 학습과 다중 사용자 접속을 완벽히 지원하는 최고 성능의 GPU 서버 인프라의 즉각적인 도입이 매우 시급

나. 국가적 필요성(NFRM 등) 국가 중장기계획과의 연계성 등

- 최근 수립된 정부 전략(제1차 국가전략기술 육성 기본계획의 '산업활용·혁신 AI', 국가 인공지능 전략의 '국가 AX 전면화' 등)에 따라 소재 산업의 AI 전환이 시급한 과제로 부상하였으나, 초거대 AI 모델을 자체적으로 학습하고 서비스화하기 위한 고성능 컴퓨팅 자원이 절대적으로 부족하여 글로벌 기술 패권 경쟁력 확보에 난항 우려

- 특히 금속 소재 분야는 데이터의 복잡성(조성, 공정, 미세조직 데이터 종류 등)이 높아, 이를 통합적으로 처리하는 10B 규모 이상의 금속 소재 특화 파운데이션 모델 개발이 필수적이며 이를 위해 막대한 연산량의 모델 학습과 대규모 합성 데이터 처리를 병목 없이 수행할 수 있는 최고 성능의 GPU 서버 인프라 확보 절실
- 이러한 초고성능 GPU 인프라를 기반으로 한 초거대 AI 파운데이션 모델의 개발 및 기업 서비스화는 첨단 소재 R&D 발전전략(소재 분야 AI 학습 인프라 확보), AI 자율제조 선도프로젝트(AI 제조 파운데이션 모델), AI+S&T 활성화 방안(과학적 파운데이션 모델 등)을 비롯해 앞선 표에 요약된 국가중점과학기술 비전 및 세부 추진 전략에 매우 부합하여 아래 표와 같이 연계 가능

관련 국가중점과학기술	국가중점과학기술과의 연계성
○ 제1차 국가전략기술 육성 기본계획('24~'28), '25년 시행계획(관계부처합동, '25.3) - 인공지능 (산업활용·혁신 AI) ○ 첨단 소재 R&D 발전전략(관계부처합동, '24.12) - 소재 분야 AI·데이터 연구 인프라 구축 ○ AI 자율제조 선도프로젝트(산업통상자원부, '24.5) - AI 제조 파운데이션 모델 ○ AI+R&DI 추진전략(산업통상자원부, '24.10) - AI 기반 자율실험실 ○ 국가 인공지능 전략(과학기술정보통신부, '24.9.) - 국가 AX(AI+X) 전면화 ○ AI+S&T 활성화 방안(관계부처합동, '25.3.12) - AI+S&T로 R&D 혁신 가속화(과학적 파운데이션 모델)	○ 12대 국가전략기술 및 50개 세부 중점 기술 - 거대 AI를 통한 소재 개발 지원 자동화는 12대 국가전략기술 중 하나인 AI 중에서도 산업 현장 도입과 활용을 위한 산업활용·혁신 AI와 연계 가능 ○ 첨단 소재 R&D 발전전략과 부합 - 소재 분야 AI 연구 생태계 구축의 핵심이 되는 AI 학습 인프라 확보, 고품질 소재 데이터베이스 구축, 소재 특화 거대 AI 모델 개발 전략과 연계 가능 ○ AI 자율제조 선도프로젝트 - 소재 분야 초거대 AI 개발은 산업부에서 계획하는 AI 제조 파운데이션 모델 개발 및 보급과 연계 가능 ○ 국가 인공지능 전략 - 제조·금융·의료바이오 등 AI 도입 효과가 높으나 AI 전환이 더딘 8대 산업별 AX(AI+X) 대책으로 활용 ○ AI+S&T 활성화 방안 연계성 - 연구 현장 AI 내재화와 차세대 신소재 설계를 위한 핵심 기술(파운데이션 모델 등)과 연계하여 초거대 AI 서비스 구축을 통해 신소재 설계의 효율성 증대

3. 연구시설·장비의 구축현황

가. 연구시설·장비 구축 현황 조사 결과

순번	시설·장비명	제조사	모델명	취득 연도	취득금액 (단위 : 백만 원)	설치 기관명 (설치지역)	공동 활용 여부 ¹⁾	장비 등록 번호 ²⁾	검색 키워드
1	고성능 GPU 컴퓨팅 클러스터	주식회사 이코어	LENOVO SR675 V3	2025	1,999.030	대구경북과학기술원 (대구)	공동활용 서비스가 가능	NFEC-2026-02-313120	고성능 GPU 서버
	High-performance GPU computing Cluster								
2	그래픽처리장치	DELL	PowerEdge XE9780	2026	744	울산대학교 산학협력단 (울산)	공동활용 허용가능	NFEC-2026-04-315092	딥러닝 서버
	Graphics Processing Unit								
3	의료 빅데이터 분석용 고성능 GPU 서버 (NVIDIA DGX B200)	(주)리더스시스템즈	NVIDIA DGX B200	2025	568.92	서울대학교병원 (서울)	단독활용 만 가능	NFEC-2025-11-310151	DGX B200
	High-Performance GPU Server for Medical Big Data Analysis								
4	딥러닝 서버	NVIDIA	DGX-H200	2026	492.25	한양대학교 산학협력단 (서울)	단독활용 만 가능	NFEC-2026-01-312807	DGX H200
	Deep Learning Server								
5	딥러닝 서버	NVIDIA	DGX-H200	2026	492.25	한양대학교 산학협력단 (서울)	단독활용 만 가능	NFEC-2026-01-312806	DGX H200
	Deep Learning Server								
6	딥러닝 서버	NVIDIA	DGX-H200	2025	495	한양대학교 산학협력단 (서울)	단독활용 만 가능	NFEC-2026-01-311979	DGX H200
	Deep Learning Server								
7	딥러닝 서버	NVIDIA	DGX-H200	2025	495	한양대학교 산학협력단 (서울)	단독활용 만 가능	NFEC-2026-01-311983	DGX H200
	Deep Learning Server								
8	AI 개발용 고성능 GPU 서버 노드	NVIDIA	DGX-H200	2025	499.4	서울대학교 산학협력단 (서울)	공동활용 허용가능	NFEC-2025-06-306705	DGX H200
	High performance GPU server node for AI development								
9	인공지능 고성능 GPU 서버	NVIDIA	DGX-H200	2025	457.050	제주대학교 산학협력단 (제주)	단독활용 만 가능	NFEC-2025-04-305877	DGX H200
	High Performance GPU Server								

순번	시설·장비명	제작사	모델명	취득연도	취득금액 (단위 : 백만 원)	설치 기관명 (설치지역)	공동 활용 여부 ¹⁾	장비 등록 번호 ²⁾	검색 키워드
10	생성형 협업지능 SDK 운용/실증/개발 지원시 스템	NVIDIA	DGX-H200	2025	699.798	한국전자기술 연구원 (서울)	공동활용 허용가능	NFEC-202 5-05-3062 79	DGX H200
	Generative cooperative intelligence SDK development system								
11	지피유 서버	NVIDIA	DGX-H200	2025	182.737.68 0	인천대학교 (인 천)	단독활용 만 가능	NFEC-202 5-03-3043 36	DGX H200
	GPU Server								
12	딥러닝 서버	NVIDIA	DGX-H200	2024	496.040	강원대학교 춘 천캠퍼스(춘천)	단독활용 만 가능	NFEC-202 5-01-3028 71	DGX H200
	Deep Learning Server								
13	딥러닝 서버	NVIDIA	DGX-H200	2024	468.952	강원대학교 춘 천캠퍼스(춘천)	단독활용 만 가능	NFEC-202 5-01-3028 25	DGX H200
	Deep Learning Server								
14	딥러닝 서버	NVIDIA	DGX-H200	2024	474.980	강원대학교 춘 천캠퍼스(춘천)	단독활용 만 가능	NFEC-202 4-11-3009 83	DGX H200
	Deep Learning Server								

※붙임 1. RED 중복성검토 서비스 결과 참조
※RED 중복성검토 서비스에서 누락된 장비가 많아 NTIS ZEUS로 직접 검색

나. 연구시설 · 장비 중복성 자체검토 결과

- 1) 대상시설·장비:
- 인공지능 학습용 서버
(AI training serverl)

2) 자체검토 결과

구분		지역중복여부 ¹⁾	중복판단 여부 ²⁾	자체검토의견 ³⁾
동일장비 중복성	동일기관내	해당없음	중복장비 아님	○ 본 과제의 핵심 연구를 차질 없 이 수행하기 위해 시스템 자원의 높은 점유율 및 가동률 유지가 필 수적으로 요구되는 상황이지만 그래픽처리장치(PowerEdge XE97 80)를 단일 과제 목적의 지속적이 고 배타적인 독점 활용 불가 ○ 더 나아가 대규모 실험 데이터
	동일지역내	해당없음		
	동일광역권내	NFEC-2026-04-315092		
	타지역	해당없음		

				보호를 위한 망 분리 등의 필수 보안 조치를 해당 장비에 대해 과제 맞춤형으로 적용할 경우 보안 유지의 특성상 활용 기간 동안 장비의 배타적 독점이 불가피하며, 본 과제의 높은 자원 활용률을 고려할 때에는 사실상 과제 전체 기간 동안 타 연구자의 접근을 차단하는 장기 독점 운용으로 이어지게 되어 공동 활용 장비의 운영 원칙상 수용 불가
유사장비 중복성	동일기관내	해당없음	중복장비 아님	○ 본 과제 연구개발을 위해 높은 활용률 점유가 요구되는 상황에서 B200, H200, 또는 H200 & L40S 기반 장비 활용 시 성능 차이 극복을 위한 가동률 추가 상승이 예상되나 과제 수행 목적의 지속적인 독점 가동 불가 ○ 본 과제의 핵심 연구를 차질 없이 수행하기 위해 시스템 자원의 높은 점유율 및 가동률 유지가 필수적으로 요구되는 상황이지만 해당 장비를 대부분이 단독활용만 가능하며 공동활용가능한 경우도 단일 과제 목적의 지속적이고 배타적인 독점 활용 불가 ○ 대규모 실험 데이터 보호를 위한 망 분리 등의 필수 보안 조치를 해당 장비에 대해 과제 맞춤형으로 적용할 경우 보안 유지의 특성상 활용 기간 동안 장비의 배타적 독점이 불가피하며, 본 과제의 높은 자원 활용률을 고려할 때에는 사실상 과제 전체 기간 동안 타 연구자의 접근을 차단하는 장기 독점 운용으로 이어지게 되어 공동 활용 장비의 운영 원칙상 수용 불가 ○ NFEC-2025-11-310151, NFEC-2026-01-312807, NFEC-2026-01-312806, NFEC-2026-01-311979, NFEC-2026-01-311983, NFEC-2025-04-305877, NFEC-2025-03-304336, NFEC-2025-01-302871, NFEC-2025-01-302825, NFEC-2024-11-300983는 단독활용만 가능
	동일지역내	해당없음		
	동일광역권내	해당없음		
	타지역	[DGX B200] - NFEC-2025-11-310151 [DGX H200] - NFEC-2026-01-312807 - NFEC-2026-01-312806 - NFEC-2026-01-311979 - NFEC-2026-01-311983 - NFEC-2025-06-306705 - NFEC-2025-04-305877 - NFEC-2025-05-306279 - NFEC-2025-03-304336 - NFEC-2025-01-302871 - NFEC-2025-01-302825 - NFEC-2024-11-300983 [H200 & L40S] - NFEC-2026-02-313120		

4. 연구시설·장비의 차별성

가. 연구시설·장비의 혁신성(innovativeness) 및 수용력(capacity)

1) 금속 소재 멀티모달 데이터 처리에 특화된 트랜스포머 엔진

- 금속 소재 파운데이션 모델은 이질적인 형태의 데이터(연속적인 기계적 물성 수치, 이산적인 합금 조성 토كن, 고해상도 미세조직 이미지 등)를 동시에 학습해야 하므로 일반적인 AI 연산보다 훨씬 복잡한 텐서 연산 요구
- 본 도입 장비는 데이터의 특성에 맞춰 연산 정밀도(FP8, FP4 등)를 하드웨어 단에서 실시간으로 자동 변환하는 최신 트랜스포머 엔진 기술을 새롭게 제공하여 이를 통해 정밀도가 생명인 합금 조성 데이터의 손실을 방지하는 동시에 방대한 미세조직 이미지 처리를 지연 없이 가속하는 특화된 수용력 확보

2) Any-to-Any 아키텍처 학습을 위한 하드웨어 기반 메모리 풀링

- 본 과제의 핵심인 조성-공정-미세조직-물성 간의 양방향(Any-to-Any) 동시 추론 및 생성 모델(Cross-Modal Transformer, PoE-MoE 구조 등)을 학습하기 위해서는 여러 개의 인코더와 디코더가 동시에 활성화되어 극심한 메모리 단편화 현상 발생
- 본 장비는 차세대 NVLink 스위치 칩을 내장하여 여러 대의 GPU 메모리를 물리적인 장벽 없이 하나의 거대한 단일 메모리처럼 묶어쓰는 새로운 혁신 기능 보유하고 있어 이러한 특화된 메모리 공유 기술은 복수의 생성형 모델(AI 시뮬레이터, 확산 모델 등)을 복합적으로 교차 학습시킬 때 발생하는 병목을 원천 제거하는 데 핵심적

3) 파운데이션 모델 및 데이터 증강용 보조 AI 모델의 실시간 동시 병렬 학습 수용력

- 무한에 가까운 금속 소재의 탐색 공간을 10B 규모 이상의 초거대 파운데이션 모델이 학습하기 위해서는, 물리 기반 AI 시뮬레이터 및 조건부 생성 모델이 수억 건의 합성 데이터를 실시간으로 만들어내어 공급하는 파이프라인 구축 필수
- 본 도입 장비는 단일 GPU를 여러 개의 독립된 하드웨어 인스턴스로 완벽히 분할하는 최신 다중 인스턴스 및 동적 자원 할당 기술을 제공. 이를 통해 파운데이션 모델의 막대한 사전학습 연산을 수행하는 동시에, ~수백 M 파라미터 규모의 보조 생성 모델 여러 개를 간섭이나 병목 없이 병렬로 구동하는 혁신적인 수용력 확보. 결과적으로 데이터 증강 모델과 메인 AI 모델이 하나의 인프라 내에서 유기적으로 연동되는 자동 설계 AI 개발 환경을 완벽하게 구현

4) LLM 에이전트 기반 자율 설계 서빙과 학습의 동시 운영 수용력

- 최종 서비스 단계에서는 금속소재 도메인 특화 LLM 에이전트가 파운데이션 모델·생성 모델·AI 시뮬레이터를 자연어 명령에 따라 자율적으로 호출·해석·반복하는 추론 서빙 워크로드가 학습 워크로드와 동일 인프라에서 상시 병행되어야 하며, 에이전트 LLM 자체(수십억~수백억 파라미터)와 호출 대상 도구 모델들이 동시에 GPU 메모리에 상주한 채로 수백~수천 회의 추론-판단-재호출 루프를 실용적 응답 시간 내에 완료해야 하는 복합 워크로드 환경 필수
- 본 도입 장비는 단일 GPU를 하드웨어 수준에서 격리된 복수의 인스턴스로 분할하는 MIG 기술과, Mission Control(Run:ai) 기반의 동적 GPU 자원 할당 기능을 결합하여, 연구진의 대규모 사전학습 작업과 LLM 에이전트의 상시 추론 서빙을 간섭 없이 동일 노드에서 병행 운영할 수 있는 수용력을 확보. 이를 통해 학습이 완료된 모델을 별도의 추론 서버로 이전하지 않고도 즉시 에이전트 파이프라인에 반영하여 학습-서빙 간 전환 지연을 제거하고, 기업 엔지니어가 자연어로 설계 요청을 보내면 에이전트가 노드 내 NVLink를 통해 도구 모델들을 지연 없이 순차 호출하는 엔드투엔드 자율 설계 서비스 환경을 단일 인프라 내에서 구현

나. 기존 연구시설 · 장비와의 차별성(differentiation)

항목	개요	강점	약점	특징
고성능 GPU 컴퓨팅 클러스터	- LENOVO SR675 V3 - 모듈형 3U GPU 서버, GPU 종류·수량을 구성에 따라 변경 가능하며 현재 H200과 L40S 혼합 구성	- H200과 L40S를 혼합 배치하여 워크로드별 역할 분담 가능 - 혼합 운영을 통해 전산 자원 활용 효율성 제고 가능 - SXM5 구성에서 Neptune 하이브리드 액냉 지원	- L40S는 HBM 기반 GPU 대비 메모리 대역폭 낮음 - FP4 Tensor Core, Attention 가속 등 기능 미지원 - DGX SW 미포함. Slurm/K8s 구성, GPU 스케줄링, 장애 복구 자동화 별도 구축 필요 - 이종 GPU 혼합 운영 작업 스케줄러 필요	- H200/L40S 혼합 운용 가능
그래픽처리 장치	- PowerEdge XE9780 (Dell)의 10U 공랭 랙 서버, NVIDIA HGX B300 NVL8 보드 탑재 - 공식 스펙상 GPU당 270GB / 1100W로 표기 - 액냉 모델은 별도 제품으로 존재	- 엔터프라이즈 관리 생태계(OpenManage 등) 통합 - 보안 기능 내장 (Silicon Root 등) - CX8 OSFP 네트워킹이 기본 포함 - 최대 스토리지 용량이 넓음	- 공랭 전용 - 멀티유저 환경에서 GPU 스케줄링과 장애 대응 별도 구축 필요 - NVIDIA AI Enterprise도 별도 라이선싱	- HGX B300 NVL8 보드 기반, NVLink 완전 인터커넥트 - Dell 엔터프라이즈 관리/보안 체계 - 10U 공랭, 별도 액냉 모델(XE9780L) 존재

의료 빅데이터 분석용 고성능 GPU 서버	- DGX-B200 - Blackwell 아키텍처 기반 DGX 시스템 - DGX-B300의 직전 세대	- DGX 턴키 플랫폼 포함 - Base Command로 Slurm/K8s 클러스터 프로비저닝과 기본 관리가 가능 - 이미 출시되어 실사용 레퍼런스와 커뮤니티 노하우가 축적된 상태 - FP4/8 혼합 추론 가능	- DGX-B300 대비 660GB 메모리 적음 - 네트워킹이 ConnectX-7 400Gb/s로 DGX-B300의 절반 - DGX-B300 대비 FP4 dense 성능이 1.5배 낮고, Attention 가속이 2배 낮음 - SW 스택이 Base Command 기반이며, 자동 복구-Run:ai 오케스트레이션 미포함	- Blackwell 아키텍처, 총 GPU 메모리 1,440GB - 72 PFLOPS training / 144 PFLOPS inference - ConnectX-7 400Gb/s 네트워킹
이외 장비	- DGX-H200 Hopper 아키텍처 기반으로 이전 세대 대비 메모리 대역폭과 용량을 극대화한 시스템 - HBM3e 메모리를 최초로 도입하여 대규모 언어 모델의 병목 현상 해소에 집중	- 기존 H100과 물리적 폼팩터가 동일하여 즉각적인 교체 및 확장 가능 - 이미 시장에서 성숙한 Hopper 소프트웨어 생태계와 검증된 안정성 - NVSwitch 7.2TB/s로 노드 내 GPU 통신 대역폭 확보 - 10x ConnectX-7으로 피크 1TB/s 양방향 네트워크 대역폭 - 30TB NVMe SSD 스토리지 용량	- NVIDIA 소프트웨어 최적화 우선순위에서 점차 후순위로 밀릴 가능성 높음 - DGX-B300의 GPU 메모리 52% 수준 - FP4 Tensor Core 부재 - 32 PFLOPS(AI) vs DGX-B300 FP4 144 PFLOPS(sparse) - NVLink GPU당 900GB/s vs DGX-B300 14.4TB/s - 네트워킹이 ConnectX-7 400Gb/s, DGX-B300의 절반 - 시스템 메모리 2TB로 DGX-B200(4TB)보다 적어	- Hopper 아키텍처 최상위, 총 GPU 메모리 1,128GB - 32 PFLOPS AI performance - NVSwitch 7.2TB/s, ConnectX-7 400Gb/s ×10
인공지능 학습용 서버 (신규 장비)	- DGX-B300 Blackwell Ultra 아키텍처 기반 8-GPU 턴키 AI 팩토리 시스템 - FP4 Tensor Core 144 PFLOPS (sparse) + - ConnectX-8 + NVLink 14.4TB/s - 하드웨어만이 아니라 운영 소프트웨어(Mission Control, AI Enterprise, DGX OS)까지 포함된 풀스택 제품	- 2.1TB GPU 메모리 + FP4 first-class 지원 - B200 대비 FP4 1.5배 및 Attention 2배 향상 - Run:ai가 멀티탑 GPU 자동 할당, 학습 중 장애 시 자동 복구, 인메모리 체크 포인팅으로 재학습 손실 제거, NVLink 토폴로지 인식 스케줄링까지 포함 - ConnectX-8 800Gb/s(비교 장비 전부 400Gb/s) + NVLink 14.4TB/s로 멀티노드 분산 학습 시 all-reduce 대역폭과 노드 내 TP 통신 모두에서 병목이 최소화	- 시스템 전력 14kW 이상 수준에 냉각까지 감안하며 높은 전력 소비 - GPU·NVLink·네트워킹·SW 스택 전체가 NVIDIA 전용 타 벤더 장비와 혼합 운영 시 관리 체계가 이원화될 가능성 존재	- FP4 first-class + Attention 2x - CX-8 800G + NVLink 14.4TB/s - Mission Control 턴키 - GPU당 성능 비교 장비 중 최고

5. 연구시설·장비 수요현황

가. 조사목적

- 본 설문조사는 소재·부품 및 다양한 분야 기관에서 소재용 인공지능 기술 개발과 소재 개발을 위한 인공지능 서비스에 대한 수요에 기여하고자 해당 분야 관련 기업/대학/연구소를 대상으로 인공지능 학습용 서버 구축을 목적으로 수요조사를 실시함.

나. 조사개요

- 조사대상: 소재·부품 산업체를 포함한 다양한 분야 기관
- 조사방법: 구조화된 질문지를 이용한 SNS 등의 비대면 정보 통신조사 실시
- 조사지역: 전국

다. 수요조사 결과

- 수요분석:

6. 연구시설·장비 도입의 적정성

구 분	내 용					
취득방법 (해당란에 '○'표시)	구 매	임 차		제작의뢰 (주문제작)	자체제작	개 발
		리스 (장기임차)	렌탈 (단기임차)			
	○					
구축비용 (단위 : 백만 원)	단가	수량	총금액	적용환율 (외자일 경우)	연도별 분할납부 금액 및 임차료 (분할납부 예정 또는 임차일 경우)	
	1,200	1	1,200	-	-	
구축비용 집행 계획 (2개 이상의 과제로 예산을 집행하거나 여러 연차에 걸쳐 분할납부 하려는 경우 과제별/연차별로 내용을 작성)	과제명		해당연차 연구기간 (YYYY-MM-DD ~ YYYY-MM-DD)	해당연차 연구비 (단위 : 백만 원)	장비 구축비용 (단위 : 백만 원)	
	금속소재 조성·공정 자동설계 초거대 AI 서비스 개발		2027-01-01~2027-08-12-31	7,799	1,200	
	합 계					
구축일정	(2027-02-01 ~ 2027-06-23)					
운영시기	2027-06-24					
활용기간	8년간					

USER 2026/04/13 18:51

－ 가격의 적정성

제작 업체	리더스시스템즈	바로에이아이	엑스퍼튼
가격 (부가세 포함)	1,187,406,000	1,242,406,000	1,220,406,000

- 국내 제작 업체들을 통해 DGX B300 시스템과 이를 운용하는데 필요한 SW 및 랙이 포함된 서버의 견적을 내본 결과 1,187 백만 원, 1,242 백만 원, 1,220 백만 원 정도 수준의 비용이 필요한 것으로 파악 [※붙임 3. 견적서]
- 해당 장비 수준의 성능이어야만 고차원 데이터를 대규모로 활용하여 파운데이션 모델을 포함한 다양한 대규모 AI 모델을 학습할 수 있는 환경이 조성될 것으로 판단되어 본 사업의 목표 기술 개발의 핵심 연구장비로 운용될 예정
- 여러 업체를 통해 구매 가능한 서버 견적을 요청하였으며, 최저가는 1,187 백만원이나 GPU 가격이 월 단위로 상승하는 모습을 보이는 만큼 심의 후 실제 구입을 하는 차년도 구매 측정 가로는 12억 원이 적정하다고 판단

7. 연구시설·장비의 구축 계획

가. 단계별 구축 전략

구분/내용	2027년					비고
	2	3	4	5	6	
구매/발주						구매처: 한국재료연구원 발주처: 한국재료연구원
최종검수 등						최종검수 날짜: 계약일로부터 약 4개월 안에 입고 전 검수 가능
입고						입고 날짜: 계약일로부터 약 4개월 안에 입고
조립/설치 (Set Up 기간)						조립기간: 2027년 5 월 말 ~ 6 월 말 설치기간: 2027년 5 월 말 ~ 6 월 말
완료 및 NTIS 등록						완료 예정일: 장비 설치 후 약 1 주 이내 NTIS 등록 예정일: 완료 직후
운용 및 활용						

- 입고 시 특이 사항: 한국재료연구원에 장비 도착하면 업체에서 방문하여 장비 설치 및 시운전 등 진행
- 조립/설치 시 특이 사항: 장비 세팅 완료 후, 기본 장비 시운전, 실제 장비가동, 교육 등은 제작 업체 전문가들에 의해서 진행
- 완료 예정일 특이 사항: 제작 업체 방문스케줄 및 한국재료연구원 장비 교육 후의 약간의 장비 운용 후 추가 교육 및 Q&A 일정 감안 필요

나. 구축환경

검 토 사 항		검 토 내 용	판 단
설치 환경 검토	공간 확보	설치될 장비의 크기에 맞는 공간이 확보 되었는가?	적합
	전기	설치될 장비에 맞는 용량의 전력은 확보 되었는가?	적합
	수도	설치될 장비에 맞는 용량의 용수는 확보 되었는가?	적합
	진동	설치될 장비가 진동에 민감할 경우, 적절한 조치는 취했나?	적합
	자기장	설치될 장비가 자기장에 민감할 경우, 적절한 조치는 취했나?	적합
	소음	설치될 장비가 소음에 민감할 경우, 적절한 조치는 취했나?	무관
	분진	설치될 장비가 분진에 민감할 경우, 적절한 조치는 취했나?	적합
	냉·난방	냉·난방기가 필요한 경우, 마련되었나?	적합
	화재설비	설치 공간에 화재설비 장치는 완비되어 있나?	적합
	위험대비	위험물(유독가스 등)을 취급하는 경우, 대비책은 마련되어 있나?	적합
	보안장치	시건 장치가 되어 있어 외부인의 출입을 적절하게 통제할 수 있나?	적합
	통신	인터넷 등 통신시설은 확보되었나?	적합
	운반	장비운반 시 건물 내 방해 또는 위험 요소가 있나?	적합
		장비 설치 시 고려사항 또는 기타 특이사항	
		- 한국재료연구원 본관동 서버실에 구축 예정 - 계산 및 AI 학습 서버 운용 중인 공간으로 전기, 수도, 화재 설비, 소음, 진동 등 설치안정성 확인	

8. 연구시설·장비의 운영계획

가. 연구시설·장비의 운영 재원, 유지 및 집행 계획

- 자체 연구 사업비 및 외부 공동활용에 따른 요금징수를 통해 운영비 확보
- ‘소비전력 + 감가상각비 + 유지보수비’를 기준으로 자체 및 공동활용에 따른 징수된 요금을 통해 유지보수 비용 확보
- 사용자의 부주의한 실수로 인하여 고장이 발생하여 보수가 필요한 경우에는, 원인 제공자 측에서 보수 비용을 담당토록 하는 것을 원칙으로 장비 운영
- 타 기관 및 기업에서의 의뢰에 대하여 데이터 생산과 인공지능 연구지원 서비스 및 연구과제를 통하여 사용료를 산정하여 장비 관리 비용을 충당하는 효과 기대

예상 연간 운영유지비 (단위 : 백만 원)	유지보수비		운영비			합계
	유지비 ¹⁾ (장비를 이상 없이 유지하기 위한 고정수리, 정비, 점검 등에 소요되는 비용)	교체비 (수명을 초과하거나 기능을 상실한 부품의 교체 비용)	운용비 ²⁾ (장비 운영 시 직접적으로 사용되는 연료비, 전기비, 가스비, 시약 및 재료 구입비)	인건비 (장비의 운영인력 및 지원부서 인력의 급여 및 수당)	관리비 (장비 관련 교육훈련 공공요금, 보험, 재배치, 폐기, 홍보물, 세금 등에 소요되는 비용)	
	45	-	20.7	-	-	65.7
신청 장비 운영유지비 집행 계획 (2개 이상의 과제로 예산을 집행하려는 경우 과제별로 내용을 작성)	과제명		해당연차 연구기간 (YYYY-MM-DD ~ YYYY-MM-DD)	해당연차 연구비 (단위 : 백만 원)	운영유지비 집행금액 (단위 : 백만 원)	
	급속소재 조성·공정 자동설계 초거대 AI 서비스 개발		2027-01-01~2028-12-31	7,799	65.7	
	합 계				65.7	

USER2026/04/13 18:51

¹⁾NFEC 유지보수비 산정기준 중대형 GPU 서버 유지보수요율 4.00% 적용
²⁾전기비(상시 가동(평균 70% 부하), PUE 1.3 기준) + 기타 재료비 적용

나. 연구시설·장비 전담 운영인력 계획

성명 (채용예정자는 000)	소속부서명	최종학위	직군	고용형태	담당장비수 ¹⁾ (신청 장비 포함)	장비운영경력
이호원	재료데이터·분석연구본부	박사	책임연구원	정규직		16년
정재면	재료데이터·분석연구본부	박사	선임연구원	정규직		7년
이지현	재료데이터·분석연구본부	박사	선임연구원	정규직		1년

¹⁾구축금액 1000만원 이상 주장비

9. 연구시설·장비의 활용 계획

가. 연구시설·장비의 활용목표

구 분		전체	기관내부 ¹⁾	기관외부 ²⁾
이용건수		연간 240 건	연간 건	연간 건
이용시간		연간 1,560 시간	연간 시간	연간 시간
이용자		연간 명	연간 명	연간 건
시료수		연간 건	연간 건	연간 건
논 문	SCI급 논문	연간 2 건		
	비SCI급 논문	연간 2 건		
특 허	삼극특허출원 ³⁾	연간 - 건		
	국내특허출원	연간 - 건		
기술이전		5년간 건	연간 - 건	
교육	프로그램	연간 건	연간 건	연간 건
	교육인원	연간 명	연간 명	연간 건

주 1) 기관내부 : 소속기관 내 인력의 이용실적 기재
2) 기관외부 : 소속기관 외 인력의 이용실적 기재
3) 삼극특허 : 미국,일본,유럽특허청에 모두 등록되어 있는 특허(Triad Patent Families)

나. 연구시설·장비의 공동활용 계획

- 1) 내부 활용계획(공동활용계획)
- 본 장비는 전략연구사업 "금속소재 조성·공정 자동설계 초거대 AI 서비스 개발" 과제의 핵심 인프라일 뿐만 아니라, 한국재료연구원 내 금속소재 빅데이터 구축, AI 기반 물성 예측, 미세 조직 분석 자동화, 소재-공정 최적화 등 AI 활용을 요구하는 다양한 연구 활동과 연계되어 운용 가능한 장비이며, 금속소재 분야의 AI 연구 역량을 기관 차원에서 확보하기 위한 필수 장비
 - 한국재료연구원 내 금속소재 파운데이션 모델 학습, AI 시뮬레이터 개발, 합성 데이터 생성 모델 학습 등에 대한 GPU 컴퓨팅 수요가 복수의 연구부서에 걸쳐 매우 높으며, 각 연구부서 간 자원 경합 없이 공동연구와 협업에 적극 활용 계획

2) 외부 활용계획(공동활용계획)

- 본 GPU 서버는 금속소재에 특화된 수십억 파라미터 규모의 파운데이션 모델을 자체 학습할 수 있는 국내 유일 수준의 온프레미스 인프라로서, 학문적으로는 전국 단위의 국내 주요 연구 중심대학 및 전문 연구소와의 금속소재 AI 공동연구에, 산업 활용 및 기업 지원 측면에서는 금속 제조업 기반의 동남권 소재 기업 및 전국 단위 대기업의 AI 기반 소재·공정 설계 공동활용에 집중할 것으로 예상되며, 수요조사 결과 주요 활용 예상 산·학·연은 아래와 같음
- 금속소재 AI 설계 서비스 및 파운데이션 모델 활용 수요: 현대자동차, 현대제철, 포스코, 삼성전자, 두산에너빌리티, 한화에어로스페이스, LG에너지솔루션, KAI 등
- 대학 및 연구기관 공동연구 수요: 경상국립대학교, 부산대학교, UNIST, GIST, 서울대학교, KAIST, 한국생산기술연구원, 국방기술품질원, 한국원자력연구원 등

다. 연구과제(사업) 종료 후 활용계획

1) 공동활용허용

- 본 장비는 ZEUS 등록을 통한 공동활용서비스를 통해 대내·외 서비스를 제공할 계획이며, 본 장비를 통해 학습된 금속소재 파운데이션 모델과 AI 기반 소재 설계 서비스 플랫폼 역시 활용하여 사업 수행 중 및 사업 종료 이후에도 산업체, 연구기관, 대학의 지원 업무 지속 계획
- 인공지능 학습용 서버 도입으로, 사업 종료 후에도 신규 합금계·공정에 대한 파인튜닝, AI 시뮬레이터 업데이트, 생성 모델 고도화 등 지속적인 모델 개선 및 신규 공동연구 수행 가능
- 사업 종료 후 발굴되는 신규 금속소재 AI 관련 국가 R&D 과제 및 산학연 협력 과제의 핵심 연구 인프라로 지속 활용
- 금속소재 AI 설계 웹 서비스 플랫폼 및 API를 통해 대·중·소기업의 소재·공정 설계 지원 업무를 적극 수행하고, 기업 자체 데이터 기반 맞춤형 파인튜닝 서비스를 제공하여 산업 현장의 AI 활용 확산

10. 연구시설·장비 구축에 따른 기대효과

가. 과학기술적측면의 기대효과 및 파급효과

1) 금속소재 거대 AI 파운데이션 모델의 자체 학습 역량 확보

- DeepMind GNoME, Microsoft MatterGen 및 MatterSim, IBM FM4M 등 해외 빅테크가 자

체 GPU 인프라를 기반으로 소재 생성·예측을 위한 파운데이션 모델을 학습하고 있는 상황에서, DGX-B300 구축을 통해 국내에서도 금속소재에 특화된 동등 규모의 파운데이션 모델을 자체 인프라에서 학습할 수 있는 컴퓨팅 기반을 확보

- 합금 조성-공정-미세조직-물성에 걸친 멀티모달 빅데이터(열역학 데이터, EBSD/SEM 미세조직 이미지, 응력-변형률 곡선, XRD 데이터 등)를 하나의 거대 모델에서 통합 학습하려면 수십억 파라미터 규모의 모델을 분산 환경에서 안정적으로 수행하기 위한 고성능 AI 학습 인프라 구축

2) 물리 기반 수치 해석을 대체하는 AI 시뮬레이터 및 가상실험실 개발 기반 마련

- 결정소성 FEM, 상장(phase-field), CALPHAD 기반 열역학 시뮬레이션 등 수일~수주가 소요되는 금속소재 수치 해석을 대체할 수 있는 AI 시뮬레이터의 학습에 필요한 고해상도 3D 공간상의 시간 발전 데이터를 대량으로 처리 가능한 대규모 GPU 메모리와 노드 내 통신 대역폭을 갖춘 학습 기반 마련
- AI 시뮬레이터를 자체적으로 학습·검증·개선하는 반복 사이클을 기관 내에서 운영할 수 있게 되어, 기존 해석 대비 동일 시간 내 탐색 가능한 조성·공정 조합의 수를 획기적으로 확대

3) 다중 대규모 모델 동시 운영 기반의 역설계 파이프라인 구현

- 금속소재 역설계(목표 물성 → 조성·공정 탐색)에는 파운데이션 모델, 생성 모델, AI 시뮬레이터, 불확실성 정량화 모델 등 수십억 파라미터 규모의 모델 여러 개를 동시에 GPU에 상주시키고 설계 루프를 반복할 수 있는 충분한 GPU 메모리와 노드 내 통신 대역폭을 지닌 인프라 확보
- 인공지능 학습용 서버를 활용하여 이러한 통합 역설계 파이프라인을 단일 노드 내에서 운영함으로써, 금속소재 자동 설계의 실질적 구현 기반을 확보

4) 금속소재 AI 연구의 해외 인프라 종속 탈피

- 현재 국내 연구기관의 대규모 모델 학습은 클라우드 GPU 서비스에 의존하는 경우가 많으나, 금속소재 데이터의 보안 민감성(전략소재 조성 정보 등)과 장기 학습의 비용 효율성을 고려하면 자체 온프레미스 인프라 확보가 필수적
- 인공지능 학습용 서버 구축을 통해 데이터 주권을 확보하면서, 해외 클라우드 의존 없이 독자적으로 금속소재 파운데이션 모델을 학습·운영·개선할 수 있는 자립적 연구 환경을 구축

나. 경제적측면의 기대효과 및 파급효과

1) 거대 AI를 통한 금속소재 R&D 생산성 제고

- MIT에 따르면 AI를 활용한 연구자들의 소재 발견(44%), 특허 출원(39%), 제품 프로토타입(17%) 개발 성과가 증가하였으며 13~15% 생산성 향상 효과가 있는 것으로 보고된 바 있고 (Artificial Intelligence, Scientific Discovery, and Product Innovation, MIT, 2024), 인공지능 학습용 서버에서 학습된 금속소재 파운데이션 모델을 통해 이러한 생산성 향상 효과를 국내 금속소재 R&D 현장에 직접 적용
- 사전 물성 예측을 통해 성공 확률이 높은 실험 조건을 우선 제안함으로써 실험 실패율과 원자재 낭비를 줄이고, 자동차·항공우주·배터리 등 금속 제조업 분야의 신소재 개발 기간을 단축

2) 핵심 전략 금속소재 국산화 가속

- 국방핵심소재의 해외 수입의존도가 50% 이상인 상황(산업연구원, 2022)에서, 인공지능 학습용 서버로 학습된 거대 AI를 통해 고온용 Ni 초합금, 고강도-고연성 이상조직강, 경량 다성분 합금 등 전략 금속소재의 조성·공정 최적화를 가속하여 국산화 및 수입 대체 효과 창출
- 특정 원소(Co, Pt, Ge 등)의 공급망 리스크를 고려한 대체 조성 설계를 AI 기반으로 체계적으로 수행할 수 있는 컴퓨팅 기반을 확보

3) 소재 정보학 시장 진입 기반 조성

- 2035년까지 3.4조 원 규모로 연평균 27.43% 성장이 전망되는 소재 정보학 시장(Materials Informatics Market Size, Share, and Trends 2025 to 2034, Precedence Research, 2024)에서, DGX-B300 인프라에서 학습된 금속소재 파운데이션 모델을 API 형태로 산업계에 제공하거나 SaaS 기반 소재 설계 서비스로 상용화하는 기반을 마련

다. 사회적측면의 기대효과 및 파급효과

1) AI-금속소재 융합 전문인력 양성 기반 확보

- 인공지능 학습용 서버가 제공 가능한 대규모 모델 학습 환경을 활용하여, 대학·출연연 연구자 및 대학원생에게 금속소재 파운데이션 모델의 사전학습·파인튜닝·추론 서빙 등 실무 교육 기회를 제공하고, 'AI 기반 소재 개발' 커리큘럼 및 워크숍·해커톤 등 실습 프로그램을 통해 차세대 AI-금속소재 융합 연구인력을 양성

- 국내 AI-소재 융합 인력 부족 문제를 해결하고, 자동차·철강·배터리 등 금속 제조업 현장에서 AI를 실제로 활용할 수 있는 실무 역량을 갖춘 인력을 배출

2) 탄소중립 목표 달성을 위한 금속소재 혁신 가속

- 경량 고강도 구조 소재, 수소저장·수소취성 저항 합금, 고효율 촉매용 합금 등 탄소중립 목표 달성에 필수적인 금속소재의 설계 및 최적화를 거대 AI로 가속함으로써, 국가 탄소중립 로드맵 이행에 실질적으로 기여

3) 개방형 혁신 연구생태계 구축 기여

- 파운데이션 모델 학습 과정에서 축적되는 금속소재 멀티모달 빅데이터 및 학습된 모델 가중치를 공공 데이터 및 오픈소스로 공개하여, 소재 분야 오픈 사이언스 문화 확산에 기여
- 구축된 GPU 인프라를 오픈하여 부족한 국내 컴퓨팅 인프라 문제를 해결하고(슈퍼컴 6호기 예타 기획보고서, 과기부, 2023), 개방형·협력형 혁신 연구생태계를 조성

라. 지역적측면의 기대효과 및 파급효과

1) 경남·부산·울산 동남권 산학연의 제조업 AX 연구 거점 구축

- 한국재료연구원 내 GPU 인프라를 구축하여, 경남 지역에 금속소재 AI 연구의 핵심 거점을 형성하고, 수도권 편중된 AI 컴퓨팅 인프라의 지역 분산에 기여
- GPU 인프라로 개발된 AI의 활용 서비스로 산학연의 소재개발 및 공정 설계를 위한 인공지능 연구 지원하고 개방형 데이터베이스와 인공지능 서비스 플랫폼 활용을 위한 전문 교육 및 지원으로 동남권 제조업 인공지능 전문가 양성

2) 경남 지역 금속소재·부품 산업체와의 협력 강화

- 경남 지역에 집적된 자동차 부품, 항공소재, 조선해양 소재, 방산 소재 산업체에 인공지능 학습용 서버에서 학습된 금속소재 AI 모델 기반의 설계 서비스를 제공하고, 기업 자체 데이터를 활용한 맞춤형 파인튜닝을 지원하여 지역 산업체의 기술 고도화를 지원
- 금속소재 웹기반 AI 서비스 플랫폼을 통해 지역 중소 제조기업도 별도의 AI 개발 없이 금속소재·공정 개발에 거대 AI를 활용할 수 있도록 접근성을 제공

- 연관기업 및 관내 학연과의 협업을 통한 데이터 기반 소재개발 사업 추진 및 연관기업에서 데이터 기반 소재개발 사업 추진 시 기술 지원

3) 인근 대학·연구기관 공동활용 및 지역 인력 정착 유도

- 창원대, 경상대, 부산대, UNIST 등 인근 대학 및 연구기관 연구자에게 대규모 GPU 학습 환경 및 이를 통해 개발된 AI 모델을 제공하고, 지역 연구역량의 전반적 상향을 도모
- 수도권이 아닌 경남 지역에서도 최첨단 GPU 인프라를 활용한 연구가 가능해짐으로써, AI-금속소재 융합 분야 석·박사급 인력의 지역 내 취업 및 정착을 유도하여 지역 두뇌 유출 완화에 기여

11. 사전기획보고서 작성절차 및 참여인력

- 사전기획 기간: 2026.01.28. ~ 2026.04.01.
- 사전기획 회의 개최: 위 기간 동안 월 1회 이상
- 참여명단 : 이호원 책임연구원, 정재면 선임연구원, 이치현 선임연구원
- 업무분장
 - 이호원 책임연구원 : 전략연구사업 “금속소재 조성·공정 자동설계 초거대 AI 서비스 개발” 과제 책임, 사업 성공 추진을 위한 장비 필요성 확인, 장비 구축에 필요 사양 확인
 - 정재면 선임연구원 : 장비 중복성 검토, 제안 장비 우수성 및 차별성 분석, 사전기획 보고서 작성
 - 이치현 선임연구원 : 장비 수요조사 및 수요조사 결과보고서 작성, 장비 견적서 확보 및 검토
- 보고서 작성 일자
 - 사전기획보고서 초안 작성 일자 : 2026.04.03.
 - 사전기획보고서 수정 일자 : 2026.04.08. (수요조사서 취합 및 보고서 내용 보완)
 - 사전기획보고서 최종 작성 일자 : 2026.04.14.